

# 葛飞翔

电话: 19857950790 邮箱: [marshall\\_gefxiang@163.com](mailto:marshall_gefxiang@163.com)

研究兴趣: 大模型; 异构软硬件推理系统

## 教育经历

中国科学院大学 | 推免硕士研究生 | 人工智能 2025.09 ~ 至今

• 荣誉经历: 国科大杭州高等研究院新生奖学金

上海对外经贸大学 | 本科 | 数据科学与大数据技术 2021.09 ~ 2025.06

• 荣誉经历: 上海市奖学金、爱建特种基金会奖学金、优秀毕业生、优秀共青团员、蓝桥杯国赛三等奖

## 业界工作

百度 | 模型适配与推理性能优化 | vLLM、SGLang、昆仑芯 2026.02 ~ 2026.08

• **LLM 推理优化**: 1) 对于 Dsv3.2 模型, 面向昆仑芯 P800, 基于 SGLang 对 NSA Indexer、MTP/投机解码开展 profiling、框架对齐与关键函数优化, 先于 GLM5.3 引入 Index Cache 机制, 使单机性能较原准出提升 20%、PD 分离提升 50%, 并定位解决投机解码乱码等一系列问题; 2) 基于上游 vLLM Workspace Manager 机制优化 vLLM-Kunlun 显存管理, 使 Qwen3-97B 单机最大上下文翻倍, 改动合入 [PR 283](#); 3) 分析算子计算强度, 发现 speculative attention 的 FP16 实现较 BF16 快 1.8 倍, 替换为更适配硬件的算子实现。

• **框架迁移、开源共建与 AI 提效**: 1) 从零迁移 vLLM-Omni 到昆仑芯, 主导多模态模型在昆仑芯的适配, 主流模型的性能达到 H20 的 80%; 2) 参与 vLLM-Kunlun 开源共建, 贡献者排名第 6/39、合入 9 个 PR, 覆盖代码重构、算子优化与显存管理; 3) 迭代 LLM 部署 SOP Skill 和准出 Agent, 自动化模型部署、性能/精度测试及结构化报告。

• **多模型适配与交付**: 完成 Qwen3/Qwen3.5、Wan、Qwen-Image、GLM-Image、Qwen-Image-Edit 的推理适配、性能精度验证与交付, 对于小模型诸如 Grounding SAM、OpenFold/SAM3、BEVFormer 等完成训练或推理场景适配, 并解决过程中暴露的一系列问题。

• **Dynamo 与 HiCache 特性适配**: 完成 SGLang + HiCache + Dynamo 整体框架调通适配及 GLM 系列验证; 修复 KV-aware 模式 DP rank 不一致 Hang 和前缀复用调度失效问题, 并在 Dynamo/Router 注入 Prometheus 指标拆解链路。经分析和优化, Dynamo 可稳定提升 TPOT 10%+, HiCache 在特定数据集使前缀命中率翻倍并显著降低 TTFT。

eBay 软件工程有限公司 | AI Platform 工程师 | Ray、Kubernetes、集群调度 2024.10 ~ 2025.08

• **平台工程**: 深入实践 Ray Data、Ray Serve 等组件, 解决多类型资源标签调度和 PyArrow 内存泄漏问题; 相关修复已合入公司内部 Ray 分支 ([PR 49124](#)、[PR 49756](#))。参与内部 AI 工作流搭建工具开发, 主要负责可观测性板块和部分核心功能开发。

• **集群优化与技术跟进**: 负责测试业务部门模型的 GPU 集群利用情况, 尽可能优化资源调度、内存管理、分布式策略等来提升 GPU 集群的利用率。曾修复 KubeRay 资源调度缺陷使 GPU 利用率翻倍, 并探索 LLM 强化学习训练的资源需求、调研框架。

## 项目经历

---

### IEEE AICAS 2026 - 面向 AI 芯片的 VLM 高效推理与优化赛道 (rank 6 / 514)

- **端到端推理加速**: 面向 PPU-ZW810E 优化 Qwen3-VL-2B-Instruct, 在 VQA 单 batch、1K 输入 / 128 token 输出评测下, 将 TTFT 从 vLLM 的约 77 ms 降至约 17 ms, 吞吐从约 220 提升至约 340 tok/s; 综合精度、TTFT 与吞吐指标取得赛道第 6 / 514 名。
- **全栈优化设计**: 构建图像、文本 Radix Tree 等多层级 KV Cache, 结合 torch.compile、Prefill/Decode CUDA Graph 多策略录图进行推理加速; 以 Triton、CUDA 和 TileLang 实现 QK RMSNorm-RoPE、FlashAttention/FlashDecode、FFN、KV 写入等关键融合算子, 并通过 trace 驱动的代码优化减少 D2H 同步与小算子 launch。

### 基于 RISC-V AI CPU 的推理优化

- **硬件感知 GEMM 优化**: 针对 RISC-V AI CPU 上 Qwen3.5-2B 的 GEMM, 结合 Roofline 与 PMU 定位 VPU 发射吞吐和非矩阵指令瓶颈; 重排为 N-major 循环、将 Q4\_1 切换至 Q4\_0、把量化 scale 分组由 32 扩至 64, 精简汇编指令。在 128-token 场景下, Prefill 相比基线提升 289% (3.89 $\times$ ), Decode 提升 57% (1.57 $\times$ )。
- **模型压缩与数据布局优化**: 将 Vision Encoder 从 24 个 ViT block 精简至 7 个, 在精度损失可控前提下使视觉 prefill 阶段吞吐翻倍; 针对 SSM build\_conv\_state 的非连续访存, 设计 64 $\times$ 64 分块转置与 L1 Cache 复用, 实现单测 7-10 $\times$ 、端到端约 10% 加速。

## 研究工作

---

- **Dynamical Adapter Fusion: Constructing A Global Adapter for Pre-Trained Model-based Class-Incremental Learning**, RuiQi Liu , Boyu Diao, Zijia An, Runjie Shao, Feixiang Ge, et al. NeurIPS 2026, CCF-A。
- **Using Domain Adapter and Prompt Learner for Few-shot Teaching Action Recognition in videos**, Feixiang Ge, Xinlei Li, Yan Rong, et al., IJCNN 2025; 第一作者, CCF-C。
- **A Hybrid CNN-Transformer Network for Fine-Grained Tongue Multi-Attribute Classification with Tongue Group Attribute Mask Training in Traditional Chinese Medicine Diagnosis**, Liu J, Ge F, Li F, et al., International Conference on Intelligent Computing, Springer Nature Singapore, 2025: 467-479; 共同一作, CCF-C。
- 《通用深度学习模型搭建与开发辅助工具》, 登记号: 2026SR0303020; 第一著作权人, 软件著作权。